大白话数值线性代数

Igloos

2024 年 7 月 3 日

1 LU 分解

求解 $Ax = b$。最通俗的解法。L 与 U 取自英文 Lower(下三角阵) 和 Upper(上三角阵)。

通过 **Gauss 消去法**一个个左乘行初等变换矩阵从而得到一个上三角阵：$L_{n-1}...L_2L_1A = U$

其中 $L_k = I - le_k$ 是形状如下的 Gauss 变换矩阵。有良好性质 $(I - le_k)^{-1} = I + le_k$。

$$\begin{bmatrix} 1 & & & & & \\ & 1 & & & & \\ & & 1 & & & \\ & & * & 1 & & \\ & & * & & 1 & \\ & & * & & & 1 \end{bmatrix}$$

Gauss 消元法能进行到底的充要条件是主元 $a_{kk}^{(k-1)} \neq 0$，即 A 的 n 阶顺序主子阵都非奇异。为规避这一点我们可以引入全主元 Gauss 消去和列主元 Gauss 消去。

运算量为 $\frac{2}{3}n^3$。全主元的选主元代价为 $\frac{1}{3}n^3$, 列主元的选主元代价为 $O(n^2)$。

利用下三角阵 Gauss 矩阵进行 LU 分解。

若 $det(A) \neq 0$，则 LU 分解唯一。

2 Cholesky 分解

求解 $Ax = b(A$ 正定)。是 LU 分解的一种特殊情况。

Cholesky 分解: $A = LL^T$，其中 Cholesky 因子 L 是唯一确定的。

可改进为 $A = LDL^T$。其中的 L, D 均唯一确定。

Cholesky 分解是稳定的，运算量为 $\frac{1}{3}n^3$。

3 最小二乘问题

求 $||b - Ax||_2$ 的最小值。

如果 $Ax = b$ 有解，$||b - Ax||_2$ 显然等于 0。

$Ax = b$ 当且仅当 $rank(A) = rank(A, b)$ 时有解，$N(A) = \{0\}$ 时有唯一解。

最小二乘定理 $||b - Ax||_2$ 在 x 处取得最小值 $\Leftrightarrow A^TAx = A^Tb$

注意到 $A^TAx = A^Tb$ 总是有解的。

3.1 正则化方法求最小二乘解

step1 计算 $C = ATA \quad d = A^T b$

step2 Cholesky 分解 $C = L^T L$

step3 求解三角方程组 $Ly = d \quad L^T x = y$

4 QR 分解

正交矩阵：$A^T A = I$。A 的行/列向量两两正交。其中 $det(A)$ =1 或-1。

正交变换：保证向量长度不变的变换。$||Tx|| = ||x||$。

任何正交变换都可以由对称变换 **(Householder 变换)**，旋转变换 **(Givens 变换)** 来复合表示。

正交矩阵根据 $det(A) = 1$ 和 $det(A) = -1$ 可分为旋转变换和镜射变换。

旋转变换 (Givens 变换)：$det(A) = 1$

镜射变换 (Householder 变换): $det(A) = -1$

4.1 Givens 变换

是一种旋转变换。可将一个向量的若干个分量化为 0.

Givens 变换矩阵: $G = \begin{bmatrix} cos\theta & sin\theta \\ -sin\theta & cos\theta \end{bmatrix}$

正交性:$G^T = G^{-1}$。

对 $x = \begin{bmatrix} a \\ b \end{bmatrix} \quad Gx = \begin{bmatrix} cos\theta & sin\theta \\ -sin\theta & cos\theta \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} r \\ 0 \end{bmatrix}$。

其中 $cos\theta = \frac{a}{r}, sin\theta = \frac{b}{r}$。

相当于将向量顺时针旋转 θ，使得向量落在 x 轴上。y 方向分量 =0。

4.2 Householder 变换

是一种镜射变换。可将一个向量除一个分量外全部化为 0。

Householder 变换矩阵: $H = I - 2\omega\omega^T (||\omega|| = 1)$

正交、对称、对合:$H^T = H^{-1} = H$。

Hx 是 x 关于垂直于 ω 的超平面的镜像反射: $x = u + a\omega \quad \omega^T u = 0 \quad \omega^T \omega = 1$

$Hx = (I - 2\omega\omega^T)(u + a\omega) = u + a\omega - 2\omega\omega^T u - 2a\omega\omega^T\omega = u - a\omega$

取 $\omega = \frac{x - ae_1}{||x - ae_1||}$，得到的 Householder 变换 $H = I - \omega\omega^T$，可使得 $Hx = ae_1$。

4.3 Gauss 变换

Gauss 变换并不是正交变换。仅仅是此处与 Givens 变换和 Householder 变换形成对照, 说明 Gauss 变换也可以将向量 0 化，但并不是保证长度不变，而是保留一个初始元素。

对 $x = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} \quad Lx = \begin{bmatrix} 1 & & & \\ -l_{21} & 1 & & \\ -l_{31} & & 1 & \\ -l_{41} & & & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} x_1 \\ 0 \\ 0 \\ 0 \end{bmatrix}$。

4.4 QR 分解

QR 分解定理 $A \in R^{m*n} = Q \begin{bmatrix} R \\ 0 \end{bmatrix}$

Q 是 m 阶正交矩阵，R 是对角元 ≥0 的 n 阶上三角阵。

若 m=n 且 $det(A) \neq 0$，则 QR 分解唯一。

利用正交矩阵 Householder 阵进行 QR 分解。

$H_1 A e_1 = \alpha_1 e_1$

$H_2 H_1 e_2 = \alpha_2 e_2$

运算量 $\frac{2n^2(m-n)}{3}$。

5 迭代法

求解 $Ax = b$。单步线性迭代格式 $x_k = Mx_{k-1} + g$，迭代收敛当且仅当 $\rho(M) < 1$。

迭代时希望得到 $x = A^{-1}b$，过程中免不了求矩阵的逆，考虑到对角矩阵的逆是容易求的。我们把普通的矩阵 A 拆成 $A = D - L - U$。

若迭代矩阵 $q = ||M|| < 1$(比 $\rho(M) < 1$ 更严格), 则近似解可被任意已知的两项控制住:

$||x_k - x_*|| \leq \frac{q^{k-n}}{1-q^{m-n}} ||x_m - x_n|| \quad m > n$

渐近收敛速度 $R_\infty(M) = -ln\rho(M)$。谱半径越小，收敛速度越快。

5.1 Jacobi 迭代法

$x_k = D^{-1}(L+U) + D^{-1}b$

A 对称且对角元 >0，则 A 与 $2D - A$ 都正定 ⇔Jacobi 迭代收敛。

A 严格对角占优/不可约对角占优 ⇒Jacobi 迭代收敛。

5.2 Gauss-Seidel 迭代法

$x_k = (D-L)^{-1}Lx_{k-1} + (D-L)^{-1}b$

注意在代码中跑 G-S 迭代时，不需要求 (D-L) 的逆!!!

$x_k(j) = D^{-1}Lx_k(1:j-1) + D^{-1}Ux_{k-1}(j+1,n) + D^{-1}b$

A 对称正定 ⇒G-S 迭代收敛。

A 严格对角占优/不可约对角占优 ⇒G-S 迭代收敛。

5.3 SOR 迭代法

$x_k = (D-\omega L)^{-1}[(1-\omega)D + \omega U]x_{k-1} + \omega(D-\omega L)^{-1}b$

(即 G-S 迭代引入松弛因子)

SOR 迭代收敛 ⇒ $0 < \omega < 2$

A 正定,$0 < \omega < 2$ ⇒SOR 迭代收敛。

泊松边值问题中，对 Jacobi 迭代矩阵 B，SOR 迭代矩阵的最优松弛因子 $\omega_{opt} = \frac{2}{1+\sqrt{1-\rho(B)^2}}$。太难了我觉得也不可能考就不细展开了...(小声

另外，SOR 的收敛速度比 Jacobi 和 G-S 迭代快上许多:

$R_\infty(B) \sim \frac{1}{2}\pi^2 h^2$

$R_\infty(L_1)$~π^2h^2
$R_\infty(L_\omega)$~$2\pi h \quad (h \to 0)$

6 最速下降法

求解 Ax=b(A 正定)。等价于求线性泛函 $\phi(x) = x^TAx - 2b^Tx$ 的极小值点。
有点类似于贪心算法：每次都沿局部梯度最大的方向下山。但不一定是全局最优。
step 1 选择负梯度作为方向 $r_k = b - Ax_k$
step 2 确定步长 $\alpha_k = \frac{r_k^Tr_k}{r_k^TAr_k}$
step 3 下山 $x_k = x_{k-1} + r_k\alpha_k$
收敛性：$||x_k - x_*||_A \le (\frac{\lambda_n-\lambda_1}{\lambda_n+\lambda_1})^k||x_0 - x_*||_A$，由 $\frac{\lambda_n-\lambda_1}{\lambda_n+\lambda_1}$ 决定，$\lambda_1 \ll \lambda_n$ 时收敛速度极慢。
若最速下降法能在有限步求得最小值，则最后一步迭代下降方向是 A 的一个特征向量。

7 共轭梯度法

7.1 共轭梯度法

求解 Ax=b(A 正定)。单方向搜索，最多迭代 n 次就能得到精确解。
step 1 选择负梯度作为方向 $r_k = b - Ax_k$
step 2 在 p_{k-1} 与 r_k 张成的平面中选取下降速度最快的方向:
$\beta_k = \frac{r_k^Tr_k}{r_{k-1}^TAr_{k-1}}$
$p_k = r_k + \beta_kp_k$
step 3 确定步长 $\alpha_k = \frac{r_k^Tr_k}{p_k^TAp_k}$
step 4 下山 $x_k = x_{k-1} + p_k\alpha_k$
收敛性：$||x_k - x_*||_A \le 2(\frac{\sqrt{k_2}-1}{\sqrt{k_2}+1})^k||x_0 - x_*||_A$，　$\kappa_2 = \kappa_2(A) = ||A||_2||A^{-1}||_2$

7.2 Krylov 子空间

共轭 (正交的一种推广)：A 是正定矩阵，若 $p_i^TAp_j = 0$, 则称 p_i 与 p_j 共轭。
对 $\{r_i\}$ 和 $\{p_i\}$ 有如下性质
1.$p_i^Tr_j = 0 \quad (i < j)$
2.$r_i^Tr_j = 0 \quad (i \ne j)$　两两正交
3.$p_i^TAp_j = 0 \quad (i \ne j)$　两两共轭
4.span$\{r_0, ..., r_k\}$=span$\{p_0, ..., p_k\}$=span$\{r_0, Ar_0, ..., A^kr_0\}$
定义 $\mathcal{K}(A, r_0, k+1)$ =span$\{r_0, ..., r_k\}$=span$\{p_0, ..., p_k\}$=span$\{r_0, Ar_0, ..., A^kr_0\}$
$r_0, ..., r_k$ 是 Krylov 子空间的正交基。
$p_0, ..., p_k$ 是 Krylov 子空间的共轭正交基。
重要的推论：$\phi(x) + x_*^TAx_* = (x - x_*)^TA(x - x_*)$
很重要的结论:$\phi(x_k) = min\{\phi(x) : x \in x_0 + \mathcal{K}(A, r_0, k)\}$, 其中线性泛函 $\phi(x) = x^TAx - 2b^Tx$。
也可以写为 $||x_k - x_*||_A = min\{||x - x_*||_A : x \in x0 + \mathcal{K}(A, r_0, k)\}$。

若系数矩阵 A 有 k 个互不相同的特征值，则 Krylov 子空间的维数最多是 k，进而共轭梯度法最多 k 步就可以得到方程组 Ax=b 的精确解。

8 幂法

8.1 幂法

求模最大特征值和对应特征向量。

$y_k = Au_{k-1}$

$\mu_k = ||y_k||_\infty$

$u_k = y_k/\mu_k$

任取向量 $u_0 \in \mathbf{C}^n$，疯狂给它作用矩阵 A，期待 $A^n u_0$ 能完全落在 x 的初始方向上。

如果矩阵 A 的最大模特征值 (主特征值)λ_1 几何重数 = 代数重数 (Jordan 块均为 1 阶)，且初始向量 u_0 没有倒霉到在 λ_1 的特征子空间上投影为 0，则向量序列 $\{A^n u_0\}$ 一定收敛于特征向量 x_1。(最好的情况是可对角化，其它数值书上都是这种简单情况，怎么小黄书这么复杂 qwq)

直观上是显然的。将 A 的特征向量扩充成一组基，x_0 可用这组基线性表示。当无穷个 A 作用于 x_0，x_0 在它多个特征子空间上的方向被不断以 λ_i 的大小持续放缩。最终“最突出”的那个方向就是最大模特征值对应的方向。若 x_0 在主特征值的特征子空间上投影为 0，则它最终“最突出”的方向是它所有投影不为 0 的特征向量中，特征值模最大的那个方向。

迭代时，为防止计算 u_k 时数值溢出，取迭代向量 $\{u_k\}$ 的最大模长为 1。

收敛速度 $=O(|\frac{\lambda_2}{\lambda_1}|^k)$。

8.2 反幂法

求模最小特征值和对应特征向量。

$Ay_k = z_{k-1}$

$\mu_k = ||y_k||_\infty$

$z_k = y_k/\mu_k$

条件：$|\lambda_n| < |\lambda_{n-1}| \leq ... \leq |\lambda_1|$

收敛速度 $=O(|\frac{\lambda_n}{\lambda_{n-1}}|^k)$。

注意反幂法每步需要求解线性方程组，运算量远大于幂法。

8.3 收缩技巧

求第二大的模特征值和对应的特征向量。

首先需要求出第一大的模特征值 λ_1 和对应特征向量 x_1

取 Householder 矩阵使得 $Hx_1 = \alpha e_1$

则 $HAH^* e_1 = \lambda_1 e_1$($HAH^*$ 的第一列情况)

且 $HAH^* = \begin{bmatrix} \lambda_1 & * \\ 0 & B_1 \end{bmatrix}$

得到的 B 的特征值为 $\lambda_2, \lambda_3 ...$

对 B 作幂法即可得到 λ_2 和 x_2。

8.4 位移

用于加速。

幂法中，位移 μ 越靠近 $|\lambda_1|$, 收敛速度 $=O(|\frac{\lambda_2-\mu}{\lambda_1-\mu}|^k)$ 越大。

$y_k = (A - \mu I)u_{k-1}$

$u_k = y_k / ||y_k||_\infty$

反幂法中，位移 μ 越靠近 $|\lambda_1|$, 收敛速度 $=O(|\frac{\lambda_2-\mu}{\lambda_1-\mu}|^k)$ 越大。

$(A - \mu I)y_k = z_{k-1}$

$z_k = y_k / ||y_k||_\infty$

P170 证明了在 μ 选取合适时往往只需要一次迭代就能得到很好的近似特征向量。

引入位移中的误差是有利的，其几乎不会影响特征向量的方向，只会让解在特征子空间中投影更大，加大了特征方向的 dominant 性。

9 QR 方法

求所有特征值和特征向量/矩阵 Schur 分解。

(为减小 QR 迭代计算量) 先上 Hessenberg 化，再通过 Givens 变换 QR 迭代直到收敛 (于 A 的 Schur 分解)。

9.1 上 Hessenberg 化

实 schur 分解定理说明了只做实数变换最多只能得到分块上三角阵，而不是上三角阵，这暗示了上 Hessenberg 化方法。

对于任意实矩阵 A，可期待其相似于一个分块上三角阵，期待其零元素越多越好。

作 Householder 变换 $H = I - 2\omega\omega^T$, 注意到 $H^T = H, H^T H = I, H^{-1} = H$，则 $\tilde{A} = HAH$ 意味着 $\tilde{A}$ 与 A 相似。

取 H_1 使得 $H_1 A = \alpha e_1$，对 $H_1 A H_1$ 又期待能尽可能多的保留 $H_1 A$ 第一列中的 0 元素。

则 H_1 应有如下形式 $\begin{bmatrix} 1 & 0 \\ 0 & \tilde{H}_1 \end{bmatrix}$

$H_1 A H_1 = \begin{bmatrix} 1 & 0 \\ 0 & \tilde{H}_1 \end{bmatrix} \begin{bmatrix} a_{11} & \alpha_2^T \\ \alpha_1 & A_2 2 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & \tilde{H}_1 \end{bmatrix} = \begin{bmatrix} a_{11} & \alpha_2^T \tilde{H}_1 \\ \tilde{H}_1 \alpha_1 & \tilde{H}_1 A_{22} \tilde{H}_1 \end{bmatrix}$

令 $\tilde{H}_1$ 为 Householder 阵，使得第一列的 3 到 n 个元素全为 0。

再对 $\tilde{H}_1 A_{22} \tilde{H}_1$ 做同样的变换，使得第二列的 4 到 n 个元素全为 0。

经过 n-2 次变换可得上 Hessenberg 阵 $H_{n-2}...H_2 H_1 A H_1 H_2 ... H_{n-2} = \begin{bmatrix} * & * & * & * & * & * \\ * & * & * & * & * & * \\ & * & * & * & * & * \\ & & * & * & * & * \\ & & & * & * & * \\ & & & & * & * \end{bmatrix}$

计算量 $O(\frac{10n^3}{3})$。

9.2 QR 迭代

核心思想：通过构造相似，保留特征值，期待某个相似矩阵形成上三角阵的形状。

$A_{m-1} = Q_m R_m$

$A_m = R_m Q_m$

不加偏移的 QR 迭代是线性收敛的,至于收敛性书上证的我压根没看懂 (肯定是书的锅)(bushi

其收敛性是：对角线趋于特征值，对角线以下趋于 0.

下给出一个 QR 迭代中，若 H_{m-1} 是上 Hessenberg 的，则 H_m 也是上 Hessenberg 的直观证明。

对于 5*5 的 Hessenberg 矩阵 $H = \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ & * & * & * & * \\ & & * & * & * \\ & & & * & * \end{bmatrix}$

$$P_{12}H = \begin{bmatrix} * & * & * & * & * \\ & * & * & * & * \\ & * & * & * & * \\ & & * & * & * \\ & & & * & * \end{bmatrix} \quad P_{23}P_{12}H = \begin{bmatrix} * & * & * & * & * \\ & * & * & * & * \\ & & * & * & * \\ & & * & * & * \\ & & & * & * \end{bmatrix} \ldots \ P_{45}P_{34}P_{23}P_{12}H = \begin{bmatrix} * & * & * & * & * \\ & * & * & * & * \\ & & * & * & * \\ & & & * & * \\ & & & & * \end{bmatrix}$$

既然是相似变换，就得右乘逆回去。注意到 Givens 变换限制在 (i,i+1) 坐标内且具有良好的顺序性质。

P_{12}^T 是 (1,2) 坐标平面内的旋转变换：相当于将第一列第二列线性组合。

则 $P_{45}P_{34}P_{23}P_{12}HP_{12}^T = \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ & & * & * & * \\ & & & * & * \\ & & & & * \end{bmatrix} \ldots \ P_{45}P_{34}P_{23}P_{12}HP_{12}^TP_{23}^TP_{34}^TP_{45}^T = \begin{bmatrix} * & * & * & * & * \\ * & * & * & * & * \\ & * & * & * & * \\ & & * & * & * \\ & & & * & * \end{bmatrix}$

(相当于给你旋转回去) 得到的 H_m 和 H_{m-1} 一样，都是上 Hessenberg 阵。

9.3 带原点位移的 QR 迭代

$H_m - \mu_m I = Q_m R_m$

$H_{m+1} = R_m Q_m + \mu_m I$

位移就是用来加速的 (比如反幂法)。在 QR 迭代中，原点位移可以使得收敛速度从线性收敛 $O(\epsilon)$ 快进到平方收敛 $O(\epsilon^2)$。下面来看是怎样通过位移加速。

通过我不会证明的那个线性收敛定理【对角线以下元素将趋于 0, 对角线元素趋于特征值】知，可期待上 Hessenberg 阵 H 的尾巴项 $h_{nn}^{(m)}$ 趋近于特征值，取位移 $u = h_{nn}^{(m)}$

将上 Hessenberg 阵通过 Givens 变换约化为上三角阵。

考虑 $H_{n-1} = \begin{bmatrix} * & * & * & * & * & * \\ & * & * & * & * & * \\ & & * & * & * & * \\ & & & * & * & * \\ & & & & * & * \\ & & & & * & * \end{bmatrix} \quad H_{n-1} - h_{nn}I = \begin{bmatrix} * & * & * & * & * & * \\ & * & * & * & * & * \\ & & * & * & * & * \\ & & & * & * & * \\ & & & & * & * \\ & & & & * & 0 \end{bmatrix}$

记左下角的 2*2 阵为 $T = \begin{bmatrix} \alpha & \beta \\ \epsilon & 0 \end{bmatrix}$

对 T 作 Givens 变换以消去ϵ

$$\begin{bmatrix} cos\theta & sin\theta \\ -sin\theta & cos\theta \end{bmatrix} \begin{bmatrix} \alpha & \beta \\ \epsilon & 0 \end{bmatrix} \begin{bmatrix} cos\theta & -sin\theta \\ sin\theta & cos\theta \end{bmatrix} = \begin{bmatrix} \sigma & \beta cos\theta \\ 0 & -\beta sin\theta \end{bmatrix} \begin{bmatrix} cos\theta & -sin\theta \\ sin\theta & cos\theta \end{bmatrix} = \begin{bmatrix} * & * \\ -\beta(sin\theta)^2 & * \end{bmatrix}$$

其中 $cos\theta = \alpha/\sigma, sin\theta = \epsilon/\sigma$。

收敛速度由 $H_{n,n-1} = -\beta(sin\theta)^2 = -\beta(\frac{\epsilon}{\sigma})^2$ 决定, 等于 $O(\epsilon^2)$,

远远优于不带位移的 QR 迭代中,

$$\begin{bmatrix} cos\theta & sin\theta \\ -sin\theta & cos\theta \end{bmatrix} \begin{bmatrix} \alpha & \beta \\ \epsilon & \delta \end{bmatrix} \begin{bmatrix} cos\theta & -sin\theta \\ sin\theta & cos\theta \end{bmatrix} = \begin{bmatrix} \sigma & \beta cos\theta + \delta sin\theta \\ 0 & -\beta sin\theta + \delta cos\theta \end{bmatrix} \begin{bmatrix} cos\theta & -sin\theta \\ sin\theta & cos\theta \end{bmatrix} =$$

$$\begin{bmatrix} * & * \\ -\beta(sin\theta)^2 + \delta sin\theta cos\theta & * \end{bmatrix}$$

收敛速度 $=\frac{\delta\alpha*\epsilon+\beta\epsilon^2}{\sigma^2} = O(\epsilon)$。

9.4 双重步位移的 QR

真难，肯定不会考 ()

不幸的是，实矩阵也可以有复特征值，位移取 h_{nn} 是实数，达不到加速效果。

对 $\begin{bmatrix} h_{n-1,n-1} & h_{n-1,n} \\ h_{n,n-1} & h_{nn} \end{bmatrix}$ 的共轭复特征值 μ_1, μ_2

连续作 2 次带位移的 QR 迭代:

$H - \mu_1 I = Q_1 R_1$

$H_1 = R_1 Q_1 + \mu_1 I$

$H_1 - \mu_2 I = Q_2 R_2$

$H_2 = R_2 Q_2 + \mu_2 I$

可得到 $H_1 = Q_1^T H Q_1 \quad H_2 = Q_2^T Q_1^T H Q_1 Q_2$

$(H - \mu_1 I)(H - \mu_2 I) = Q_1 R_1 (Q_1 Q_2 R_2 Q_1^{-1}) = Q_1 Q_2 R_2 R_1$

定义 $M = (H - \mu_1 I)(H - \mu_2 I) = H^2 - (\mu_1 + \mu_2)H + \mu_1\mu_2 I$

则有 QR 分解 $M = (Q_1 Q_2)(R_2 R_1) = QR$

我们就可以合并这 2 步迭代, 直接从 H 得到 H_2:

step1:$M = H^2 - trace(H)H + det(H)I$

step2:$M = QR$

step3:$H_2 = Q^T H Q$

可避开复数运算但计算量 $O(n^3)$，改进如下:

注意到 $M = (H - \mu_1 I)(H - \mu_2 I) = H^2 - (\mu_1 + \mu_2)H + \mu_1\mu_2 I$ 有如下形式:

$$\begin{bmatrix} * & * & * & * & * & * \\ * & * & * & * & * & * \\ & * & * & * & * & * \\ & & * & * & * & * \\ & & & * & * & * \\ & & & & * & * \end{bmatrix} \begin{bmatrix} * & * & * & * & * & * \\ * & * & * & * & * & * \\ & * & * & * & * & * \\ & & * & * & * & * \\ & & & * & * & * \\ & & & & * & * \end{bmatrix} = \begin{bmatrix} * & * & * & * & * & * \\ * & * & * & * & * & * \\ * & * & * & * & * & * \\ & * & * & * & * & * \\ & & * & * & * & * \\ & & & * & * & * \end{bmatrix}$$

由 6.4.3，只要 Hesseberg 分解的 $Q^T H Q = H_2$ 与 $\tilde{Q}^T H \tilde{Q} = \tilde{H}_2$ 中 Q 与 $\tilde{Q}$ 的第一列相同，则 H_2 和 $\tilde{H}_2$ 近似等价。

那我们就取 Householder 矩阵 P_0 使得 P_0 与 Q 第一列相同，即 $P_0 e_1 = Q e_1$

注意到 Me_1 后前 3 个元素可能不为 0,n-3 个元素都为 0。之所以用 Householder 而不用 Givens 是因为不为 0 的元素数量 >2。

$M = QR$，则 Q 的第一列与 M 的第一列共线: $\alpha Q e_1 = M e_1$,α 是矩阵 R 的左上角元素。

取 Householder 矩阵 P_0 使得 $P_0(Me_1) = \alpha e_1$。

则 $P_0(\alpha Q e_1) = \alpha e_1$，又 Householder 矩阵 $P_0 = P_0^{-1}$，则 $P_0 e_1 = Q e_1$。

则 $P_0 = diag(\tilde{P}_0, I_{n-3})$ 对上 Hessenberg 阵 H 作 Householder 变换，只改变其前三列。

后面取的 $P_1, P_2 ...$ 不要影响到第一列即可，则上三角为单位阵。

$$P_0 H = \begin{bmatrix} * & * & * & * & * & * \\ & * & * & * & * & * \\ & * & * & * & * & * \\ & & * & * & * & * \\ & & & * & * & * \\ & & & & * & * \end{bmatrix} \quad P_0 H P_0 = \begin{bmatrix} * & * & * & * & * & * \\ * & * & * & * & * & * \\ + & * & * & * & * & * \\ + & + & * & * & * & * \\ & & & * & * & * \\ & & & & * & * \end{bmatrix}$$

取 $P_1 = diag(1, \tilde{P}_1, I_{n-4})$

$$P_1 P_0 H P_0 P_1 = \begin{bmatrix} * & * & * & * & * & * \\ * & * & * & * & * & * \\ & * & * & * & * & * \\ & + & * & * & * & * \\ & + & + & * & * & * \\ & & & & * & * \end{bmatrix}$$

取 $P_k = diag(I_k, \tilde{P}_k, I_{n-k-3})$

$$H_2 = P_4 P_3 P_2 P_1 P_0 H P_0 P_1 P_2 P_3 P_4 = \begin{bmatrix} * & * & * & * & * & * \\ * & * & * & * & * & * \\ & * & * & * & * & * \\ & & * & * & * & * \\ & & & * & * & * \\ & & & & * & * \end{bmatrix}$$

该算法运算量为 $10n^2$。

参考文献